

UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea in Informatica



Progetto di Esame

Architetture Avanzate e Strumenti Formali di Bioinformatica

Framework di “Precision Safety” per l’Esclusione Terapeutica

Candidato: Francesco De Stasio

Matricola: 0522501768

Anno Accademico 2025/2026

Indice

1	Introduzione	2
2	Analisi	2
3	Progettazione	3
4	Architettura della rete Siamese	4
5	Coding	5
5.1	Snippet di codice e analisi delle funzioni principali	6
5.2	Analisi critica dei risultati sperimentali	8
6	Dataset	10
7	Formule e Metodi	12
8	Conclusioni e considerazioni	15

Sommario

Si presenta di seguito l'estratto del lavoro di analisi, progettazione e scrittura del progetto **"Framework di "Precision Safety" per l'Esclusione Terapeutica"**; Il progetto verte sullo sviluppo di un approccio Safety-First nell'ambito della medicina di precisione, ribaltando il paradigma classico dell'inferenza causale. L'obiettivo è identificare formalmente chi non deve essere trattato, isolando i sottogruppi di pazienti per i quali il trattamento standard risulta tossico o inefficace (o entrambi) rispetto a un'alternativa più conservativa.

1 Introduzione

Verrà illustrato quali scelte il progettatore ha deciso di implementare; l'analisi effettuata sulla tipologia di progetto e la morfologia del modello, lo studio sulla conseguente *Contrastive Loss* utilizzata, gli esempi da cui si è potuto apprendere in che modo vengono utilizzati questi modelli e con quali scopi. In fondo non per importanza verranno fatti anche degli accenni sul [dataset](#), che ha permesso la costruzione di questo modello di rete di inferenza, di come siano state utili ai fini del risultato ottenuto le features e i target interni.

2 Analisi

L'avvento della medicina di precisione ha storicamente focalizzato i propri sforzi sull'identificazione del Conditional Average Treatment Effect (CATE), orientando i modelli predittivi verso la massimizzazione del beneficio terapeutico atteso. Tuttavia, dal punto di vista della sicurezza clinica, tale paradigma presenta una vulnerabilità intrinseca: l'assenza di un segnale esplicito di reiezione nei casi in cui il trattamento standard non si limiti a essere inefficace, ma risulti attivamente tossico o iatrogeno. Il presente lavoro si propone di formalizzare un framework di *Precision Safety*, invertendo radicalmente l'obiettivo dell'inferenza causale per isolare ex-ante i soggetti da sottoporre a esclusione terapeutica.

Dal punto di vista computazionale, la traduzione del concetto clinico di "profilo biologico a rischio" in una metrica decisionale deterministica richiede il superamento dei limiti strutturali della classificazione binaria standard. I modelli tradizionali di classificazione risentono fortemente dello sbilanciamento delle classi e tendono a mappare i confini decisionali su metriche di verosimiglianza assolute, fallendo nel catturare le sottili relazioni di prossimità geometrica che intercorrono tra le risposte fisiologiche dei pazienti.

La scelta metodologica è ricaduta pertanto sulle reti Siamesi (*Twin Networks*), un'architettura nativamente deputata al *metric learning*. Invece di forzare la rete ad apprendere una funzione di mappatura diretta verso uno spazio di probabilità discreto, il modello viene addestrato a proiettare le caratteristiche baseline del paziente in uno spazio vettoriale latente compresso. In questo spazio, le distanze geometriche riflettono la similarità topologica dei profili clinici rispetto agli endpoint di sicurezza. L'analisi preliminare evidenzia come tale approccio consenta di astrarre una rappresentazione robusta e invariante rispetto ai bias di selezione clinica, ponendo le basi per una policy restrittiva di tipo *Safety-First*.

3 Progettazione

La progettazione architetturale del framework risponde a rigidi criteri di ingegneria del software orientata agli oggetti (OOP), strutturando la pipeline in moduli indipendenti e debolmente accoppiati per garantire riproducibilità, manutenibilità e scalabilità clinica.

Il flusso informativo si articola secondo la seguente sequenza logica modulare:

1. **Data Ingestion e Validazione di Stato (DatasetManager)**: Modulo deputato al recupero stocastico dei dati grezzi e alla gestione delle anomalie. Al fine di garantire la convergenza della rete e prevenire l'instabilità dei gradienti dovuta a scale eterogenee (es. l'età confrontata con le conte linfocitarie absolute), il modulo applica una normalizzazione Z-score. La validazione di stato intercetta ex-ante eventuali chiamate inconsistenti del flusso prima delle fasi di splitting stratificato.
2. **Generazione di Contrasto (SiamesePatientDataset)**: Estensione custom della classe `Dataset` di PyTorch. Il modulo ingegnerizza la creazione in tempo reale di coppie di pazienti (x_i^1, x_i^2) , bilanciando statisticamente al 50% le coppie genuine (medesimo outcome clinico) e le coppie impostore (outcome discordanti). Tale bilanciamento stocastico impedisce alla rete di collassare verso soluzioni banali durante l'ottimizzazione.
3. **Estrazione delle Feature (SiameseTwinNet)**: Struttura a pesi totalmente condivisi (*Weight Sharing*). L'architettura prevede un singolo blocco di trasformazione non lineare composto da strati densi completamente connessi, regolarizzati mediante `BatchNorm1d` (per stabilizzare la covarianza interna) e `Dropout` (per contrastare l'overfitting strutturale). La simmetria dei pesi garantisce l'invarianza formale della distanza rispetto all'ordine di inserimento della coppia.
4. **Valutazione della Policy (PrecisionSafetyEvaluator)**: Il modulo clinico di *Deployment*. Questo componente non partecipa all'addestramento dei gradienti, ma opera nello spazio latente stabilizzato. Isola i vettori d'esperienza passata associati a esiti infausti, ne calcola il baricentro geometrico (Centroide di Pericolo) e definisce un confine di tolleranza radiale (r) entro il quale far scattare formalmente l'esclusione terapeutica per i nuovi pazienti in ingresso.

4 Architettura della rete Siamese

L'efficacia del framework di *Precision Safety* dipende strettamente dalla configurazione geometrica dello spazio latente in cui i profili biologici dei pazienti vengono mappati. La scelta di implementare una rete Siamese classica risponde alla necessità di mappare relazioni di prossimità non lineari tra feature strutturalmente eterogenee. Dal punto di vista puramente topologico, una rete neurale convenzionale apprende una funzione di partizione dello spazio di input mediante iperpiani decisionali rigidi, il che si rivela inefficace quando l'obiettivo non è la categorizzazione netta, ma l'estrazione di un indice di continuità clinica del rischio.

L'elemento cardine di questa architettura è il meccanismo di *Weight Sharing* (condivisione totale dei parametri sinaptici). La struttura consta di una singola sotto-rete neurale (*Twin Network*), istanziata una sola volta in memoria, che viene applicata sequenzialmente o in parallelo a entrambi i vettori di input x_1 e x_2 . Matematicamente, questo garantisce l'invarianza formale e la simmetria intrinseca della proiezione latente:

$$d(f_{\theta}(x_1), f_{\theta}(x_2)) = d(f_{\theta}(x_2), f_{\theta}(x_1))$$

Se non si utilizzassero pesi condivisi, l'ordine di inserimento dei pazienti nella pipeline altererebbe la distanza calcolata, distruggendo la consistenza clinica delle traiettorie geometriche e invalidando il calcolo del successivo Centroide di Pericolo.

L'architettura interna della sub-network è strutturata come un percettore multistrato profondo (*Deep Feed-Forward Network*), progettato seguendo criteri di regolarizzazione robusta per l'elaborazione di dati tabulari bioinformatici:

- **Strati Densamente Connessi (nn.Linear):** Il passaggio iniziale proietta le 18 feature baseline nello spazio a 64 dimensioni, seguito da una contrazione intermedia a 32 dimensioni, fino a giungere alla proiezione finale nello spazio latente compresso ad 8 dimensioni ($m = 8$). Questa progressiva riduzione della dimensionalità agisce da collo di bottiglia informativo (*information bottleneck*), forzando la rete a scartare il rumore di fondo stocastico del dataset ACTG 175 per isolare unicamente i macro-pattern biologici associati alla tossicità o al fallimento.
- **Funzioni di Attivazione non Lineari (ReLU):** L'introduzione della non-linearità tramite rettificatori lineari unitari consente di apprendere le interazioni complesse e non additive tra le variabili cliniche (ad esempio, l'effetto combinato di una bassa conta iniziale di CD4 associata a un elevato punteggio di Karnofsky).
- **Normalizzazione Batch (BatchNorm1d):** Posizionata immediatamente dopo le attivazioni, normalizza gli output intermedi di ciascun minibatch per avere media zero e varianza unitaria. Questa scelta è fondamentale per contrastare il fenomeno dell'*internal covariate shift*, stabilizzando la dinamica dei gradienti e consentendo l'adozione di un *learning rate* più aggressivo (0.002) senza incorrere in divergenze numeriche.
- **Regolarizzazione stocastica (Dropout):** Impostato con una probabilità di spegnimento del 20% ($\rho = 0.2$). Durante ogni iterazione dell'addestramento, una frazione casuale di neu-

roni viene disattivata. Questa tecnica costringe la rete a sviluppare una rappresentazione distribuita e ridondante dell'informazione, impedendo che l'ottimizzazione si focalizzi eccessivamente su singole feature dominanti (come l'andamento isolato dei CD4) e mitigando il rischio di overfitting strutturale dovuto alle dimensioni limitate del campione clinico.

5 Coding

L'implementazione algoritmica è stata ingegnerizzata interamente in Python sfruttando l'ecosistema `PyTorch` per il calcolo tensoriale e `Scikit-Learn` per le metriche statistiche. Di seguito si analizza la scomposizione delle classi fondamentali coerentemente con i principi OOP applicati.

La classe `SiameseTwinNet` eredita da `nn.Module` e incapsula la sotto-rete neurale tramite il costrutto `nn.Sequential`. Il flusso di *forward-pass* riceve due tensori distinti ma, invocando internamente lo stesso metodo `forward_once`, applica la medesima trasformazione sinaptica, proiettando gli input nell'embedding dimensionale compresso:

```
def forward(self, x1, x2):
    embedding1 = self.forward_once(x1)
    embedding2 = self.forward_once(x2)
    return embedding1, embedding2
```

La funzione di ottimizzazione è governata dalla classe `ContrastiveLoss`. Per ragioni di stabilità numerica e per prevenire derivate indefinite o esplosioni dei gradienti in corrispondenza di distanze prossime allo zero, il calcolo della distanza euclidea è stato implementato integrando un fattore di tolleranza $\varepsilon = 1e - 6$ all'interno dell'operatore `pairwise_distance`. La dinamica dei gradienti agisce in modo duale: minimizza la distanza per coppie ad outcome identico e applica un vincolo di penalità condizionato dal `torch.clamp` qualora la distanza di coppie discordanti non superi la barriera imposta dal `margin`.

Il ciclo di addestramento, incapsulato in `SiameseTrainer`, implementa la retropropagazione dell'errore tramite l'ottimizzatore stocastico Adam. La fase di *inference* sul singolo paziente, esposta da `PrecisionSafetyEvaluator`, riceve un vettore di input grezzo, ne muta la dimensionalità in una matrice bidimensionale compatibile mediante `reshape(1, -1)` e applica rigorosamente lo `scaler.transform` calcolato sul training set, evitando fenomeni distorsivi e preservando l'integrità statistica del modello.

5.1 Snippet di codice e analisi delle funzioni principali

Per comprendere l'esatta corrispondenza tra le equazioni teoriche e la loro controparte computazionale, si analizzano di seguito i componenti core implementati nel framework.

Il blocco fondamentale che governa la geometria di contrasto è incapsulato nella classe `ContrastiveLoss`. Di seguito viene riportata l'implementazione del metodo `forward`, deputato al calcolo della perdita di batch:

```
def forward(self, embedding1, embedding2, label):
    # 1. Calcolo numericamente stabile della distanza euclidea element-wise
    euclidean_distance = torch.nn.functional.pairwise_distance(
        embedding1, embedding2, eps=1e-6
    )

    # 2. Penalizzazione delle coppie simili (label = 1)
    loss_similar = label.squeeze() * torch.pow(euclidean_distance, 2)

    # 3. Penalizzazione delle coppie dissimili (label = 0) condizionata dal margine
    loss_dissimilar = (1.0 - label.squeeze()) * torch.pow(
        torch.clamp(self.margin - euclidean_distance, min=0.0), 2
    )

    # 4. Riduzione del batch tramite media aritmetica
    loss_contrastive = torch.mean(loss_similar + loss_dissimilar)
    return loss_contrastive
```

L'analisi riga per riga evidenzia le seguenti scelte ingegneristiche:

1. L'invocazione di `pairwise_distance` calcola la norma L_2 tra i due tensori di embedding. L'inclusione esplicita del parametro `eps=1e-6` (ε) è una precauzione numerica vitale: nel caso in cui la rete proietti due pazienti esattamente nello stesso punto dello spazio latente ($d = 0$), il calcolo del gradiente della radice quadrata produrrebbe una divisione per zero ($\frac{1}{2\sqrt{0}}$), causando il collasso dell'ottimizzazione tramite valori NaN. L'aggiunta di ε sposta il calcolo in un dominio differenziabile.
2. La variabile `loss_similar` traduce il termine $y_i d_i^2$. La funzione `squeeze()` viene utilizzata per allineare le dimensioni dei vettori tensoriali, rimuovendo le dimensioni singole superflue ed evitando broadcasting errati in PyTorch.
3. Il calcolo di `loss_dissimilar` implementa la barriera del margine: l'operatore `torch.clamp(..., min=0.0)` riflette esattamente la funzione matematica $\max(0, m - d_i)$. Se la distanza tra due pazienti con outcome diversi è già superiore al `margin` impostato, l'espressione si azzera e il gradiente non applica alcuna forza correttiva. Se la distanza è inferiore, il termine assume valore positivo e genera un gradiente repulsivo proporzionale al quadrato dell'errore.

La seconda componente critica è la logica di estrazione del *Centroide di Pericolo* e la successiva validazione della policy, implementata all'interno della classe `PrecisionSafetyEvaluator`:

```
def calculate_danger_centroid(self, train_features, train_labels):
    self.model.eval()

    # Isolamento dei profili clinici ad alto rischio storico
    danger_patients = train_features[train_labels == 1]
    t_danger_patients = torch.FloatTensor(danger_patients).to(self.device)

    with torch.no_grad():
        # Forward pass singolo per estrarre le coordinate latenti
        danger_embeddings = self.model.forward_once(t_danger_patients)
        # Calcolo del baricentro geometrico lungo l'asse dei campioni
        self.danger_centroid = danger_embeddings.mean(dim=0, keepdim=True)
```

Il metodo si distingue per l'adozione delle *best practices* di ottimizzazione della memoria in ambiente PyTorch. L'invocazione preventiva di `self.model.eval()` è obbligatoria per disattivare lo stato stocastico dei moduli di `Dropout` e congelare le statistiche correnti di `BatchNorm1d`; se omessa, il calcolo del centroide verrebbe distorto dal campionamento casuale dei neuroni, inficiando la determinazione della policy.

Inoltre, il contesto introdotto da `with torch.no_grad()` comunica esplicitamente al motore autograd di PyTorch l'inutilità di allocare memoria per il grafo dei gradienti. Poiché questa fase esegue una pura operazione di inferenza e aggregazione statistica sui dati di training, l'esclusione del tracciamento dei gradienti riduce drasticamente l'occupazione della memoria RAM/VRAM e accelera la velocità computazionale del framework. Il calcolo finale tramite `mean(dim=0)` collassa la matrice degli embedding in un singolo vettore riga rappresentante il baricentro topologico del rischio clinico.

5.2 Analisi critica dei risultati sperimentali

L'analisi quantitativa dei log di addestramento e delle metriche di validazione consente di valutare empiricamente il comportamento geometrico dello spazio latente e l'efficacia clinica della conseguente policy di esclusione.

Al termine delle 1000 epoche di ottimizzazione, la *Contrastive Loss* media si stabilizza in un range asintotico compreso tra 0.222 e 0.235, indicando il raggiungimento di un plateau di convergenza numerica. Tuttavia, l'esame congiunto delle metriche intrinseche di coppia e delle metriche estrinseche della policy evidenzia un fenomeno di forte asimmetria computazionale, di cruciale interesse clinico.

Tabella 1: Quadro comparativo delle metriche di coppia e di policy

Metriche di Coppia (Distanza)	Valore	Metriche di Policy (Esclusione)	Valore
Soglia Ottimale (t^*)	0.8634	Tasso di Esclusione (<i>Exclusion Rate</i>)	73.83%
Accuracy di Coppia	53.30%	Sensibilità Clinica (<i>True Positive Rate</i>)	81.22%
F1-Score di Coppia	0.6528	Specificità Clinica (<i>True Negative Rate</i>)	33.49%
ROC-AUC di Coppia	0.5235	Precision della Policy	54.75%
Distanza Media (Simili)	0.4999	False Positive Rate (FPR)	66.51%
Distanza Media (Diversi)	0.5301	False Negative Rate (FNR)	18.78%




Figura 1: Rappresentazione grafica delle metriche della policy asimmetrica di esclusione.

Interpretazione dello Spazio di Contrasto

Le metriche pure di classificazione delle coppie (Accuracy $\approx 53.3\%$, ROC-AUC ≈ 0.523) risultano statisticamente prossime alla linea di base casuale. Questo andamento trova una precisa spiegazione geometrica analizzando le distanze medie latenti: i pazienti biologicamente simili registrano una distanza media di 0.499, mentre i pazienti dissimili si attestano su una media di 0.530.

Questo ridotto delta geometrico ($\Delta d = 0.0302$) indica che la rete Siamese incontra una resistenza strutturale nel separare nettamente l'intero dataset in due cluster polarizzati e mutuamente esclusivi. Tale fenomeno è fisiologico nell'elaborazione di dati tabulari clinici complessi come l'ACTG 175, dove i profili biometrici baseline dei pazienti affetti da HIV presentano un'elevata sovrapposizione entropica nelle prime fasi della malattia, indipendentemente dall'outcome a lungo termine.

Tuttavia, la matrice di confusione delle coppie:

$$CM_{\text{pairs}} = \begin{pmatrix} 188 & 797 \\ 137 & 878 \end{pmatrix}$$

mostra che, a fronte di una soglia di distanza ottimale di 0.8634, il modello privilegia drasticamente il contenimento dei Falsi Negativi di coppia ($FN = 137$), proiettando un elevato volume di campioni verso la classificazione di similarità. Questo comportamento, pur penalizzando l'Accuracy globale, si traduce in un vantaggio strategico quando si passa dalla geometria simmetrica alla policy clinica asimmetrica.

Valutazione della Policy di Esclusione Clinica

L'applicazione del Centroide di Pericolo su 854 pazienti storici sposta radicalmente l'asse valutativo. Il framework applica una regola di protezione restrittiva, determinando un tasso di esclusione terapeutica pari al 73.83%. I risultati sul test set dimostrano il raggiungimento dell'obiettivo primario di *Precision Safety*:

- **Massimizzazione della Sensibilità (81.22%)**: Il framework è in grado di intercettare e proteggere ex-ante l'81.22% dei pazienti che andrebbero incontro a tossicità iatrogena o fallimento terapeutico se trattati con il protocollo standard.
- **Contenimento del False Negative Rate (18.78%)**: Clinicamente, il Falso Negativo rappresenta lo scenario più catastrofico (paziente ad alto rischio classificato erroneamente come idoneo e sottoposto al farmaco nocivo). Il modello riduce questo rischio sotto la soglia critica del 20%.
- **Trade-off sulla Specificità (33.49%) ed Elevato FPR (66.51%)**: Il costo computazionale e clinico di tale livello di sicurezza si riflette in un'elevata quota di Falsi Positivi. Il sistema manifesta una condotta fortemente conservativa, escludendo dal trattamento anche una frazione significativa di pazienti (66.51% dei sani) che avrebbero potuto tollerare il farmaco.

In conclusione, sebbene lo spazio latente mantenga una parziale sovrapposizione geometrica, l'ancoraggio della policy attorno al Centroide di Rischio permette di estrarre un classificatore asimmetrico ottimale per contesti clinici regolati dal principio di precauzione. Il framework sacrifica l'efficienza generale del trattamento (accettando un elevato tasso di falsi allarmi) pur di garantire una barriera di protezione quasi totale contro gli eventi clinici avversi.

6 Dataset

La validazione empirica del framework è stata condotta sul dataset clinico **ACTG 175** (*AIDS Clinical Trials Group Study 175*), uno studio randomizzato controllato volto a confrontare l'efficacia della monoterapia con Zidovudina rispetto a terapie combinate in pazienti affetti da infezione da HIV-1.

Un'analisi critica preliminare della morfologia dei dati ha rivelato la necessità di una profonda operazione di ristrutturazione biologica delle variabili per conformarsi agli obiettivi del framework ed evitare il catastrofico fenomeno del *Data Leakage*:

- **Definizione dell'Endpoint di Rischio Composito**: Originariamente, l'UCI Machine Learning Repository mappa la progressione della malattia (endpoint primario) all'interno del target `cid`, mentre l'interruzione precoce della terapia per tossicità ed eventi avversi è registrata come feature sotto la colonna `offtrt`. Per i fini del nostro approccio *Safety-First*, queste due informazioni sono state fuse operando una disgiunzione logica (OR elemento per

elemento). Il target sintetico risultante identifica lo stato *Unsafe* (1) per ogni paziente che abbia sperimentato o il fallimento terapeutico o l'intolleranza biologica al farmaco.

- **Filtrazione Clinica Baseline:** Per costringere la rete a operare una vera predizione ex-ante, sono state rimosse tutte le feature correlate con l'evoluzione temporale o condizionate dall'esito stesso. Nello specifico, sono state rimosse le colonne `treat` e `trt` (scelte terapeutiche), `time` (giorni di follow-up, fortemente legati alla sopravvivenza) e gli stessi componenti dell'endpoint (`cid`, `offtrt`).

La matrice finale delle feature baseline comprende 18 indicatori puramente clinici e demografici misurati al tempo zero (tra cui l'età, il peso, il punteggio di Karnofsky, la presenza di sintomi iniziali e le conte di linfociti CD4 e CD8 al baseline e a 20 settimane), consentendo al modello di mappare la vulnerabilità intrinseca del paziente prima della somministrazione effettiva del trattamento.

7 Formule e Metodi

Notazione

Sia $f_\theta : R^p \rightarrow R^m$ la **rete siamese** che proietta un paziente x in un embedding $e = f_\theta(x) \in R^m$. Indicheremo con $d(\cdot, \cdot)$ la distanza euclidea nello spazio degli *embedding*.

Distanza euclidea nello spazio latente

Per due embedding e_1, e_2 :

$$d(e_1, e_2) = \|e_1 - e_2\|_2 = \sqrt{\sum_{k=1}^m (e_{1,k} - e_{2,k})^2}.$$

Nel codice si usa la versione numericamente stabile tramite `pairwise_distance`.

Contrastive Loss

Per una coppia (x_i^1, x_i^2) con label $y_i \in \{0, 1\}$ ($1 = \text{simili}$, $0 = \text{diverse}$) e distanza $d_i = d(f_\theta(x_i^1), f_\theta(x_i^2))$ la perdita per campione è:

$$\ell_i = y_i d_i^2 + (1 - y_i) (\max(0, m - d_i))^2,$$

dove $m > 0$ è il margin. La loss del batch è la media:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N \ell_i.$$

Selezione della soglia di distanza

Si costruisce uno score associato alla similarità come $s_i = -d_i$ (più alto $\Rightarrow$ più probabile simili). Variando la soglia τ su s si ottiene la curva ROC con:

$$\text{TPR}(\tau) = \frac{\text{TP}(\tau)}{\text{TP}(\tau) + \text{FN}(\tau)}, \quad \text{FPR}(\tau) = \frac{\text{FP}(\tau)}{\text{FP}(\tau) + \text{TN}(\tau)}.$$

Nel progetto la soglia ottimale τ^* è scelta massimizzando $\text{TPR} - \text{FPR}$:

$$\tau^* = \arg \max_{\tau} (\text{TPR}(\tau) - \text{FPR}(\tau)).$$

La soglia sullo spazio delle distanze corrispondente è $t^* = -\tau^*$ (cioè decisione “simili” se $d < t^*$).

Metriche per classificazione di coppie

Dati i conteggi della matrice di confusione TP, FP, TN, FN:

- *Accuracy*:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}.$$

- *Precision*:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (\text{zero_division} = 0 \text{ se denominatore} = 0).$$

- *Recall (Sensitivity)*:

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}.$$

- *F1-score*:

$$\text{F1} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

- *ROC-AUC*: area sotto la curva ROC,

$$\text{AUC}_{\text{ROC}} = \int_0^1 \text{TPR} \, d(\text{FPR}).$$

- *Average Precision (AP)*: area sotto la curva precision-recall (definizione integrale analoga):

$$\bar{d}_{\text{sim}} = \frac{1}{|S_1|} \sum_{i \in S_1} d_i, \quad \bar{d}_{\text{diff}} = \frac{1}{|S_0|} \sum_{i \in S_0} d_i,$$

con S_1 l'insieme delle coppie etichettate simili e S_0 le diverse.

Policy di esclusione (Precision Safety)

- *Centroide di pericolo*: sia $S_{\text{danger}} = \{i : y_i = 1\}$ l'insieme dei pazienti storici ad alto rischio; gli embedding corrispondenti sono $e_i = f_{\theta}(x_i)$. Il centroide è:

$$c = \frac{1}{|S_{\text{danger}}|} \sum_{i \in S_{\text{danger}}} e_i.$$

- *Distanza di un nuovo paziente x dal centroide*:

$$d_c(x) = \|f_{\theta}(x) - c\|_2.$$

- *Regola di esclusione*: dato un raggio critico r , il paziente è escluso se

$$E(x) = \begin{cases} 1 & \text{se } d_c(x) < r \\ 0 & \text{altrimenti.} \end{cases}$$

- *Tasso di esclusione*:

$$\text{ExclusionRate} = \frac{1}{N} \sum_{i=1}^N E(x_i).$$

- *Metriche di sicurezza della policy* (usando le stesse definizioni di TP, FP, TN, FN ma riferite all'evento "escluso" vs "reale outcome");
- *Sensitivity* (True Positive Rate):

$$\text{Sensitivity} = \frac{\text{TP}}{\text{TP} + \text{FN}}.$$

- *Specificity*:

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}}.$$

- *Precision*:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}.$$

- *False Positive Rate*:

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}.$$

- *False Negative Rate*:

$$\text{FNR} = \frac{\text{FN}}{\text{FN} + \text{TP}}.$$

Note implementative

- Per stabilità numerica nelle distanze si usa un piccolo ε nell'operazione di `pairwise_distance`.
- La selezione della soglia tramite ROC considera gli score $s = -d$ perché distanze minori corrispondono a maggiore similarità.
- Tutte le medie e i rapporti prevedono gestione del caso di denominatore zero (come fatto nell'implementazione).

8 Conclusioni e considerazioni

Il framework sviluppato dimostra l'efficacia dell'applicazione delle reti Siamesi e del *metric learning* nell'ambito della *Precision Safety*. Attraverso la compressione geometrica delle caratteristiche cliniche dei pazienti, il modello è stato in grado di strutturare uno spazio latente in cui la vicinanza topologica riflette fedelmente il rischio biologico potenziale, permettendo l'estrazione di una policy di esclusione terapeutica oggettiva e quantificabile tramite la definizione del raggio critico r . I risultati sperimentali evidenziano un'elevata sensibilità nell'intercettare ex-ante i soggetti suscettibili di eventi avversi gravi o fallimento terapeutico, minimizzando il "danno evitabile" sulla popolazione.

Considerazioni Future e Sviluppi

Nonostante la robustezza matematica dimostrata, si identificano diverse direttrici per l'estensione futura del framework:

1. **Integrazione di Vincoli di Equità Clinica (*Fairness*):** Lo spazio latente generato dalle reti Siamesi può riflettere e amplificare bias sistematici presenti nei dati storici relativi a variabili demografiche sensibili (es. **race**, **gender**). Uno sviluppo futuro prioritario prevede l'introduzione di penalizzazioni di *Fairness Adversarial* nella loss function, al fine di forzare l'indipendenza degli embedding latenti da tali attributi e garantire una policy di esclusione equa.
2. **Transizione verso le Triple Networks:** Il passaggio dall'attuale architettura a coppie a un'architettura basata su *Triplet Loss* (ancora, esempio positivo, esempio negativo) consentirebbe di ottimizzare contemporaneamente i confini di vicinanza e quelli di allontanamento, aumentando la risoluzione geometrica attorno al Centroide di Pericolo.
3. **Validazione Multicentrica ed Eterogeneità dei Trattamenti:** Estendere l'addestramento a dataset oncologici o cardiovascolari permetterebbe di testare la generalizzabilità del framework su pattern di tossicità differenti, validando il sistema come strumento universale di supporto alle decisioni cliniche nei protocolli di approvazione dei farmaci ad alto rischio.