

Progetti di Bioinformatica

Introduzione

Di seguito è riportata una descrizione dei progetti attualmente disponibili. I progetti coprono temi di **bioinformatica**, **machine learning**, **deep learning** e **reinforcement learning**, con applicazioni in ambito oncologico, virologico e di biologia computazionale.

Ogni progetto può essere adattato in base al numero di componenti del gruppo e può includere sia una componente teorica sia una parte sperimentale e implementativa.

Elenco dei Progetti

1. eccDNA

Il progetto ha come obiettivo la costruzione di una rete neurale in grado di stimare la **tipologia di cancro** e il **tessuto di origine** a partire da dati di *extrachromosomal DNA* (eccDNA). L'approccio prevede l'utilizzo di **funzioni di similitudine** e architetture di apprendimento metrico basate su **triplet loss**, per apprendere rappresentazioni latenti discriminative delle sequenze.

2. VirusRL

Il progetto consiste nell'utilizzo di tecniche di **Reinforcement Learning** per la **classificazione tassonomica dei virus**. Un aspetto centrale è lo studio della capacità del modello di **generalizzare a nuovi virus emergenti**, mai osservati durante la fase di addestramento, rendendo l'approccio particolarmente rilevante in contesti epidemiologici.

3. Circular MSA

Questo progetto riguarda l'**allineamento multiplo di sequenze** (Multiple Sequence Alignment) per sequenze circolari. L'obiettivo è sviluppare un nuovo approccio basato su una rappresentazione tramite **cilindri** e introdurre **nuove metriche di similarità** adatte a questo contesto, confrontandole con metodi classici di MSA.

4. Virus Taxonomy con Graph Neural Networks

Il progetto mira a utilizzare e sviluppare **Graph Neural Networks (GNN)** per affrontare il problema della **tassonomia virale**. Le sequenze vengono rappresentate tramite diverse tipologie di grafi, tra cui:

- grafo di overlap;
- grafo di De Bruijn;
- eventuali nuove rappresentazioni grafiche progettate ad hoc.

Il lavoro non si limita all'applicazione di modelli esistenti, ma prevede la **proposta di nuovi approcci**, sia a livello di costruzione del grafo sia di architettura e funzione di apprendimento, con l'obiettivo di confrontare sistematicamente le diverse soluzioni e valutarne l'impatto sulle prestazioni di classificazione e sulla capacità di generalizzazione.

5. Probability-ecDNA

In questo progetto si studia il **propensity score** di una sequenza genomica a diventare un eccDNA. L'obiettivo è modellare, tramite tecniche di machine learning o deep learning, la probabilità che un determinato frammento genomico dia origine a eccDNA, analizzando i fattori biologici e strutturali coinvolti.

6. Covid FCGR

Il progetto prevede la **classificazione delle sequenze della proteina Spike del virus SARS-CoV-2**. Le sequenze vengono rappresentate tramite **Frequency Chaos Game Representation (FCGR)** e analizzate usando **reti neurali convoluzionali (CNN)**, anche integrando tecniche di **superpixel** per migliorare l'interpretabilità e l'efficienza del modello.

7. Framework per l'Inferenza di Gene Regulatory Networks (GRN)

Il progetto riguarda l'**inferenza di Gene Regulatory Networks (GRN)**, ovvero la ricostruzione delle reti di regolazione genica. L'obiettivo è comprendere **quali geni regolano quali altri geni** e inferire potenziali **nuovi fattori di trascrizione** a partire da dati di espressione genica, utilizzando modelli computazionali avanzati.

Il framework può essere sviluppato adottando approcci alternativi e confrontabili, tra cui:

- **Graph Neural Networks (GNN)**, modellando esplicitamente le interazioni tra geni come un grafo di regolazione;
- modelli **sequence-based** basati su **Mamba / State Space Models**, per catturare dipendenze a lungo raggio e dinamiche temporali nei profili di espressione.

L'obiettivo è confrontare le diverse architetture in termini di accuratezza, interpretabilità e capacità di inferire nuove relazioni di regolazione.

8. Framework per l'Inferenza di Disease Progression Networks (DPN)

Il progetto riguarda l'**inferenza di Disease Progression Networks (DPN)**, ovvero la ricostruzione delle reti di evoluzione delle patologie e delle comorbidità. L'obiettivo è comprendere **quali patologie predispongono o causano quali altre patologie** e inferire potenziali **eventi clinici scatenanti (driver)** a partire da dati di storie cliniche longitudinali (prescrizioni e diagnosi), utilizzando modelli computazionali avanzati.

Il framework viene sviluppato adottando e confrontando approcci di Deep Learning complementari, tra cui:

- **Graph Neural Networks (GNN)**, modellando esplicitamente le relazioni tra malattie (codici ICD9) e farmaci (ATC) come un **grafo di comorbidità**, dove i nodi sono gli eventi clinici e gli archi rappresentano la probabilità di co-occorrenza o causalità;
- modelli **sequence-based** basati su **Mamba / State Space Models**, per catturare le dipendenze a lungo raggio nella storia del paziente (es. una diagnosi di 3 anni fa che influenza il rischio attuale) e le dinamiche temporali irregolari tra le visite.

L'obiettivo finale è confrontare le diverse architetture in termini di accuratezza nella predizione del prossimo evento clinico, interpretabilità delle traiettorie di malattia e capacità di inferire nuove relazioni di rischio non ancora codificate nelle linee guida standard.

9. Framework di "Precision Safety" per l'Esclusione Terapeutica

Il progetto verte sullo sviluppo di un approccio **Safety-First** nell'ambito della medicina di precisione, ribaltando il paradigma classico dell'inferenza causale. L'obiettivo è identificare formalmente **chi non deve essere trattato**, isolando i sottogruppi di pazienti per i quali

il trattamento standard risulta tossico o inefficace (o entrambi) rispetto a un'alternativa più conservativa.

Il framework può essere sviluppato adottando strategie di stima causale complementari, tra cui:

- architetture **Dual-CATE (Conditional Average Treatment Effect)**, stimando separatamente e in parallelo le superfici di risposta per l'efficacia clinica (Y) e per la tossicità (Z) tramite ensemble methods (es. XGBoost/Random Forest);
- modelli di **Constrained Policy Learning** o reti neurali **Multi-Task**, per apprendere rappresentazioni latenti condivise tra beneficio e rischio e ottimizzare direttamente il trade-off terapeutico.

L'obiettivo è confrontare le diverse policy decisionali in termini di riduzione degli eventi avversi ("danno evitabile") e mantenimento dell'efficacia complessiva sulla popolazione. Uso del dataset: *ACTG175_UCI*

- 10. Mutual Information CATE.** Proponiamo un'architettura di deep learning end-to-end per la *Causal Subgroup Discovery*. Il nucleo del metodo è una regolarizzazione basata sulla *Mutual Information* che agisce su una variabile latente discreta G , interpretabile come assegnazione a sottogruppi causali. L'obiettivo di ottimizzazione consiste nel minimizzare $I(G; T)$, al fine di ridurre il *selection bias* intra-gruppo, e nel massimizzare simultaneamente $I(G; Y | T)$, così da catturare l'eterogeneità dell'effetto causale condizionata al trattamento. Questo approccio consente di evitare procedure di clustering post-hoc, apprendendo direttamente una rappresentazione delle covariate ottimizzata per l'inferenza causale e la stima del CATE a livello di sottogruppo.

Una volta individuato il progetto di interesse, gli studenti sono invitati a inviare una e-mail al docente per confermare la disponibilità, ricevere ulteriori dettagli tecnici e concordare le modalità di avvio del lavoro.